

Aluguel de casas: fazendo predições sobre o valor de aluguel decasas.

## Importação dos dados

```
setwd("D:\\07 04 2020\\Documents\\Edgar\\Projetos\\Data_sciece\\DataScience_projects\\Vendas_casa")
library("tidyverse")

## -- Attaching packages ----- tidyverse 1.3.0 --
## v ggplot2 3.3.2      v purrr  0.3.4
## v tibble  3.0.1      v dplyr  1.0.0
## v tidyr   1.1.0      v stringr 1.4.0
## v readr   1.3.1      v forcats 0.5.0

## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()

dados<- read.csv("houses_to_rent_v2.csv", header = T)
ndados<-nrow(dados)
View(dados)
```

## Limpeza e Preparação dos dados

Organização do cabeçalho para que seja possível manusear as variáveis com mais facilidade.

```
# Exlcuindo os caracteres ..R.. que estão depois do nome da variavel.
cab<-names(dados)
cab<-cab%>% str_remove_all("..R..")
colnames(dados)<- cab
```

Os dados são separados em treino e teste, sendo 80% para treinar e 20% para testar o modelo.

```
n_treino<- (70/100)*ndados
set.seed(100)
ua<- sample(n_treino)
treino<- dados[ua,]; View(treino)
teste<- dados[-ua,]; View(teste)
```

## Treinamento do modelo

```
model<- lm(total~.,data= treino)
```

## Avaliação da performance do modelo

Para a avaliação da performance do modelo foi utilizado três métricas, sendo elas erro médio absoluto, percentual médio do erro absoluto e coeficiente de determinação ( $R^2$ ). Também foi avaliado a distribuição dos erros dentro de quartis.

```

predito<-predict(model, teste)
per<- teste %>% select("city", "total")%>%
  mutate(predito) %>% mutate(erro= total-predito )%>%
  mutate(erro_abs= abs(erro))%>%mutate(erro_perc= erro/total)%>%
  mutate(erro_percabs= abs(erro_perc))
per[,c(4:7)]<-round(per[,c(4:7)], 5)

```

```

# Calculando o erro medio absoluto e percentual medio
erro_medio<- mean(per$erro_abs)
erro_percmed<- mean(per$erro_percabs)
summary(per$erro_percabs)

```

```

##      Min.   1st Qu.   Median     Mean  3rd Qu.    Max.
## 0.0000000 0.0000300 0.0000600 0.0002021 0.0001500 0.2589400

```

Cálculo do coeficiente de determinação ( $R^2$ ), ele varia entre 0 e 1 e indica o quão bem ajustado o modelo está, quanto mais próximo de 1 melhor a performance do modelo.

```

# Calculando o coeficiente de determinacao
resumo<- summary(model)
r2<- resumo$adj.r.squared
performance<- data.frame(erro_medio, erro_percmed,r2)
performance

```

```

##      erro_medio erro_percmed      r2
## 1  0.7203906  0.000202048 0.9999999

```